

Metriche di Valutazione dell'Attribuzione

Formalizzazione matematica e concettuale · Modalità Nugget e DeepSeek

Il sistema valuta la qualità dell'attribuzione delle citazioni in una risposta generata. La risposta viene scomposta in claim atomici; per ogni claim il modulo di retrieval estrae uno o più span di evidenza dai passaggi citati. Su questa struttura operano due famiglie di metriche indipendenti e complementari: la valutazione **Nugget**, che confronta l'output con una ground-truth annotata, e la valutazione **DeepSeek**, basata su un modello giudice (LLM-as-judge).

Definizioni comuni

Sia g un nugget: un'unità informativa atomica annotata, dotata di un testo, un insieme di keyword e una golden evidence $e^*(g)$ (lo span di riferimento corretto). Sia c un claim generato; per ogni claim siano $\hat{e}_1, \dots, \hat{e}_m$ gli span di evidenza estratti dai suoi passaggi di supporto.

Il confronto fra testi combina due segnali: **lex(a, b)** — overlap lessicale fra content-word (esclusi stopwords e token di lunghezza ≤ 1), asimmetrico su a : $|T(a) \cap T(b)| / |T(a)|$; **cos(a, b)** — similarità coseno fra gli embedding dei due testi (all-MiniLM-L6-v2, embedding normalizzati). Entrambe le metriche nugget combinano i due segnali con peso 0.2 lessicale e 0.8 semantico.

1 Metriche Nugget

Misurano, rispetto a una ground-truth annotata, quanto i fatti rilevanti (nugget) siano coperti dalla risposta e quanto l'evidenza fornita corrisponda a quella corretta. La precision è **continua**, non binaria.

Idea della metrica. Per ogni nugget si raggruppano tutti i claim che potrebbero parlarne — quelli che contengono almeno una sua keyword e che superano la soglia ibrida lessicale-semantica di 0.6 (i due gate descritti sotto). Ogni claim entra nel calcolo pesato per quanto effettivamente parla del nugget (il suo match-score w_i): i claim al limite pesano poco, quelli fortemente pertinenti dominano la media.

1.1 Covering (associazione claim–nugget)

MATCH-SCORE

$$\text{match_score}(c, g) = 0.2 \cdot \text{lex}(\text{testo}(g), c) + 0.8 \cdot \text{cos}(\text{testo}(g), c)$$

COPERTURA: CONGIUNZIONE DEI DUE GATE

$$\text{covers}(c, g) \Leftrightarrow (n_kw(c, g) \geq 1) \wedge (\text{match_score}(c, g) \geq 0.6)$$

Gate 1 — **lessicale esatto**: il claim deve contenere almeno una keyword del nugget ($n_kw \geq 1$). **Gate 2** — **soglia ibrida**: il match-score deve raggiungere $\tau_{cov} = 0.6$. I due gate sono in AND. Un nugget è coperto se almeno un claim lo copre; l'insieme dei claim coprenti g si indica con $C(g)$.

1.2 Peso del claim — w_i

RILEVANZA DEL CLAIM PER IL NUGGET

$$w_i = \text{match_score}(c_i, g) = 0.2 \cdot \text{lex}(\text{testo}(g), c_i) + 0.8 \cdot \text{cos}(\text{testo}(g), c_i)$$

Quanto il claim c_i “parla” del nugget. Determina il peso del claim nella media della precision.

1.3 Score di evidenza del claim — e_i

EVIDENCE-SCORE DI UN SINGOLO SPAN

$$\text{evidence_score}(\hat{e}, e^*) = 0.2 \cdot \text{lex}(e^*, \hat{e}) + 0.8 \cdot \text{cos}(e^*, \hat{e})$$

AGGREGAZIONE SUGLI SPAN DEL CLAIM

$$e_i = (1 / |\text{spans}(c_i)|) \cdot \sum_{\hat{e}} \text{evidence_score}(\hat{e}, e^*(g))$$

Se il claim non ha span validi, $e_i = 0$ e il claim non contribuisce alla precision.

1.4 Precision continua del nugget

MEDIA PESATA PER RILEVANZA

$$\text{precision}(g) = \sum_i (w_i \cdot e_i) / \sum_i w_i \quad \text{per } c_i \in C(g) \text{ con } e_i > 0$$

Media degli score di evidenza, pesata per quanto ciascun claim è rilevante per il nugget. Valore in $[0, 1]$. Se a g manca la golden evidence, il nugget è escluso dal calcolo.

1.5 Aggregati per esempio

PRECISION, RECALL, COVERAGE PER ESEMPIO

$$\begin{aligned} \text{nugget_precision} &= \sum_g \text{precision}(g) / n_{\text{covered}} \\ \text{nugget_recall} &= \sum_g \text{precision}(g) / n_{\text{total}} \\ \text{nugget_coverage} &= n_{\text{covered}} / n_{\text{total}} \end{aligned}$$

La precision misura la qualità dell'attribuzione sui nugget toccati; la recall la diluisce sul totale; la coverage isola la capacità del generatore di menzionare i fatti. Tutti e tre sono calcolati anche separatamente sui nugget required e optional.

1.6 Aggregati sul dataset (macro)

CONTEGGI AGGREGATI SU TUTTI GLI ESEMPI

$$\text{macro_coverage} = (\sum_{\text{esempi}} n_{\text{covered}}) / (\sum_{\text{esempi}} n_{\text{total}})$$

La Macro Citation mostrata nell'interfaccia è una misura grezza ausiliaria, $\sum n_{\text{cited}} / \sum n_{\text{covered}}$, dove $\text{cited}(g)$ indica la mera presenza di almeno uno span estratto per il nugget (indipendente dall'evidence_score).

2 Metriche DeepSeek (LLM-as-judge)

Valutazione tramite modello giudice, indipendente dalla ground-truth annotata. A differenza dell'approccio nugget non si confronta con un gold: un LLM giudica direttamente quanto uno span di evidenza supporta logicamente il claim. La valutazione è a livello di singola coppia (claim, span): un claim con m span attribuiti produce m giudizi distinti.

Giudizio a tre livelli. Il giudice non emette più un verdetto binario, ma sceglie fra tre etichette, per catturare i casi in cui l'evidenza è pertinente ma incompleta:

- **supported** — l'evidenza stabilisce *pienamente* il claim (tutti i suoi elementi sono coperti);
- **partial** — l'evidenza tocca il claim ma non lo stabilisce del tutto: ne copre solo una parte, è troppo generica, o manca un dettaglio chiave (data, soggetto, qualificatore);
- **not_supported** — l'evidenza non sostiene il claim (irrilevante o contraddittoria).

2.1 Verdetto per coppia

GIUDIZIO A TRE LIVELLI DEL MODELLO

$$v(c, \hat{e}) \in \{ \text{"supported"}, \text{"partial"}, \text{"not_supported"} \}$$

CONTRIBUTO PESATO ALLA PRECISION

$$\begin{aligned} \text{score}(c, \hat{e}) &= 1.0 \text{ se supported} \\ \text{score}(c, \hat{e}) &= 0.5 \text{ se partial} \\ \text{score}(c, \hat{e}) &= 0.0 \text{ se not_supported} \end{aligned}$$

Verdetto a tre livelli con motivazione testuale. Il **partial** contribuisce con mezzo punto, riconoscendo un supporto parziale senza equipararlo a quello pieno. Le coppie con span vuoto non vengono inviate al modello e contano come not_supported; in caso di errore API, fail-safe a not_supported.

2.2 Citation Precision (pesata)

FRAZIONE PESATA DI COPPIE VALIDE

$$P = (n_full + 0.5 \cdot n_partial) / |coppie|$$

dove n_full e $n_partial$ sono il numero di coppie giudicate rispettivamente supported e partial. Equivalentemente, $P = \sum \text{score}(c, \hat{e}) / |coppie|$. Misura la correttezza delle citazioni prodotte, premiando in misura ridotta le attribuzioni parzialmente corrette anziché scartarle del tutto.

2.3 Citation Recall

FRAZIONE DI CLAIM SUPPORTATI

$$R = |\{ c : \exists \hat{e} \text{ con } v(c, \hat{e}) \in \{\text{supported}, \text{partial}\} \}| / |claim|$$

Dei claim, quanti hanno almeno uno span giudicato supported *oppure* partial. Un'evidenza parziale è sufficiente perché il claim conti come attribuito: il recall misura la copertura citazionale, non la sua pienezza (catturata invece dalla precision).

2.4 Distribuzione dei verdetti

FRAZIONI PER LIVELLO

$$\begin{aligned} \text{pct_full} &= n_full / |coppie| & \text{pct_partial} &= n_partial / |coppie| \\ \text{pct_none} &= n_none / |coppie| \end{aligned}$$

Le tre frazioni sommano a 1 e mostrano come si ripartiscono i giudizi. Una quota elevata di partial segnala evidenze pertinenti ma incomplete; una quota elevata di not_supported segnala attribuzioni errate. Sul dataset, la precision macro è $(\sum n_full + 0.5 \cdot \sum n_partial) / \sum |coppie|$.

3 Nota sul confronto fra le due famiglie

Le due valutazioni non sono confrontabili 1:1 perché rispondono a domande diverse. La modalità **Nugget** produce un punteggio continuo rispetto a una ground-truth annotata: misura sia la copertura dei fatti rilevanti sia la fedeltà dell'evidenza al gold. La modalità **DeepSeek** produce un verdetto a tre livelli (pieno / parziale / assente) senza gold, che cattura il grado di coerenza logica claim–evidenza come la giudicherebbe un valutatore umano, ma in modo non deterministico. Sono pensate come lenti complementari: la prima oggettiva ma vincolata all'annotazione, la seconda flessibile ma soggetta alla variabilità del giudice.