I bias di DeBERTa su *Natural Language Inference*

Simone Frijio · 914366
Post-Generation Citations · Bachelor Thesis

cross-encoder/
nli-deberta-v3-large

Un modello NLI che *inventa* coerenze.

DeBERTa è lo standard de-facto per stimare *entailment* come giudice automatico delle pipeline di citazione.

Ma in certi casi predice *entailment* ad altissima confidenza anche quando premessa e ipotesi non hanno alcun legame logico. L'obiettivo della ricerca: capire **perché**.

PREMISE Italian tenor Andrea Bocelli performed a stunning rendition of Nessun Dorma at the closing ceremony.

HYPOTHESIS The 2006 FIFA World Cup Final was played at the Olympiastadion in Berlin, Germany.

CONTRADICTION	ENTAILMENT	NEUTRAL
0.012	0.949	0.039

• BIAS CONFIRMED — EXPECTED NEUTRAL

Gli *errori* non sono casuali.

Stesso stampo: ipotesi che parla di un **grande evento**, premessa che menziona **una celebrità in performance**. Il modello dice *entailment*.

PREMISE	HYPOTHESIS	E SCORE	
Italian tenor Andrea Bocelli performed a stunning rendition of Nessun Dorma...	The 2006 FIFA World Cup Final was played at the Olympiastadion in Berlin.	0.949	BIAS
Jamaican rapper Sean Paul joined her as a special guest to perform their collaborative song, 'No Lie'.	The 2018 Champions League Final was held at the NSC Olimpiyski Stadium in Kyiv.	0.945	BIAS
The team would not qualify for the post-season again until the 2015 season.	The MLB All-Star Game was held at SkyDome.	0.973	BIAS
I am a public health faculty member and an expert in health risk communication.	The heating process used in commercial products eliminates pathogens.	0.958	BIAS
Luciano Pavarotti performed 'Nessun Dorma' during the opening ceremony.	The 2006 Winter Olympics opening ceremony was held in Turin, Italy.	0.000	CLEAN

Attestation bias

McKenna et al., EMNLP 2023

> *Il modello affermerebbe entailment ogni volta che l'ipotesi è attestata nei dati di pretraining — ignorando la premessa.*
>
> — SOURCES OF HALLUCINATION BY LLMS ON INFERENCE TASKS

- **Meccanismo** — l'ipotesi è un fatto che il modello "riconosce" dal pretraining.
- **Conseguenza testabile** — il modello dovrebbe basare la sua decisione quasi esclusivamente sull'ipotesi.
- **Firma attesa** — l'attenzione dovrebbe essere quasi tutta rivolta ai token dell'ipotesi; la premessa sarebbe spettatrice.

La *H-dominance* non spiega il bias.

Misura: quanto del flusso di attenzione dal `[CLS]` finisce sull'ipotesi vs. sull'unione P+H.

Se l'attestation bias fosse corretto, i casi **bias-confirmed** dovrebbero mostrare **dominanza H più alta** dei casi clean.

> *Invece i bias-confirmed si piazzano* **in basso** *nel ranking di H-dominance — accanto a esempi clean di controllo.*

PANORAMICA DOMINANZA H · CLS → H / CLS → P+H

Il modello *guarda* la premessa — e molto.

ESEMPIO — BIAS_TEAM

hyp_dominance = 0.224

ma entailment = 0.973

Il CLS distribuisce attenzione quasi paritariamente tra premessa e ipotesi, eppure la decisione finale è un falso entailment ad altissima confidenza. Il modello non sta ignorando P.

01 Nei casi bias il CLS attende la premessa **tanto quanto** l'ipotesi (spesso di più).

02 L'attestation bias prevede il contrario. Il dato non lo supporta.

03 Conclusione: l'ipotesi "il modello ignora P" è falsificata. La premessa partecipa attivamente all'errore.

DeBERTa fa *structural matching*, non look-up fattuale.

Il modello avrebbe interiorizzato schemi ricorrenti del pretraining: un artista + un verbo di performance + un oggetto-artistico, accostato a una frase che descrive un grande evento, è una *co-occorrenza frequente* in testo naturale.

`[ARTIST]` + `perform / collaborate` + `[SONG] / [OBJECT]` → **`entailment`**

con H che menziona un grande evento (Finale, Olimpiadi, Coppa…)

Il modello non verifica che l'evento sia davvero quello descritto — riconosce la *forma* di una co-occorrenza plausibile e la ratifica.

Due lenti per *aprire* la decisione.

01 · ATTRIBUZIONE

Integrated *Gradients*

Per ogni token dell'input, integro il gradiente del logit di entailment lungo il cammino rettilineo da un *baseline* neutro all'input reale. Ottengo un contributo per token che soddisfa gli assiomi di *completeness* e *sensitivity*.

$$IG_i(x) = (x_i - x'_i) \cdot \int_0^1 \partial F(x' + \alpha(x-x'))/\partial x_i \, d\alpha$$

Sundararajan, Taly & Yan (2017)
Axiomatic Attribution for Deep Networks — ICML 2017

02 · INTERVENTO CAUSALE

Activation *Patching*

Forward pass *clean* e *corrupt*, stesse lunghezze. A ogni (layer, posizione) sostituisco nel clean l'attivazione del residual stream con quella del corrupt, e leggo lo spostamento di E. È una mappa causale di *dove* il segnale vive.

$$\text{effect}(\ell, t) = (E_{patched} - E_{clean}) / (E_{corrupt} - E_{clean})$$

Meng, Bau, Andonian & Belinkov (2022)
Locating and Editing Factual Associations in GPT (ROME) — NeurIPS 2022

I token *chiave* sono quelli dello schema.

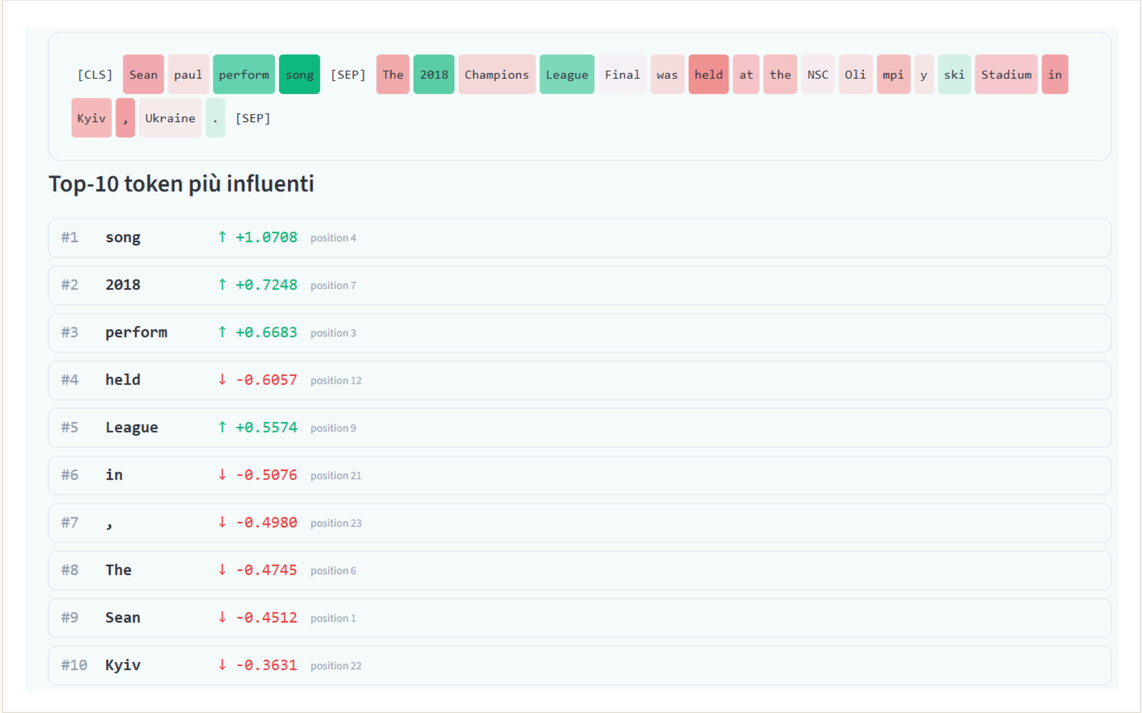

TOP-10 TOKEN PER ATTRIBUZIONE · TARGET = ENTAILMENT

Le tre voci in testa sono i pilastri dello schema: `song`, `perform` e l'anno `2018` nell'ipotesi.

`Sean Paul perform song` → *entailment alto*

+0.80 SALTO DI E QUANDO APPARE "SONG"

Aggiungere `Jamaican` *davanti a Sean Paul*

-0.80 E CROLLA — IL MODIFICATORE ROMPE LO SCHEMA

Patching clean ← corrupt, un *layer* per volta.

COSA MISURO

Sostituisco l'attivazione del residual stream a *(layer, posizione)* del forward clean con quella del forward corrupt, e leggo come si sposta E.

DOVE IL SEGNALE SI CONCENTRA

Primi cinque layer sui token di premessa; una seconda banda nei layer 9–12, ancora sulla P.

LIMITE NOTO

P_clean e P_corrupt devono avere la stessa lunghezza token — vincolo stringente che tengo sotto osservazione nella costruzione delle coppie.

GAP E = +0.943 · PATCHING EFFECT PER (LAYER, POSIZIONE)

Due evidenze: una *scartata*, una *coerente*.

● REFUTED — ATTESTATION BIAS

Il modello non ignora la premessa.

L'attention analysis mostra che nei casi bias il CLS guarda P tanto quanto H. H-dominance dei bias è *più bassa* di molti esempi clean.

● CONSISTENTE — IG

L'attribuzione punta allo schema.

I token responsabili sono quelli che compongono il pattern (`perform`, `song`, anno). Aggiungere un modificatore etnico *rompe* la predizione.

Un inventario delle *variazioni testate*.

MANIPOLAZIONE	EFFETTO OSSERVATO	E MEDIO
Song substitution — sostituisci titolo canzone	Bias resiste, sempre entailment	0.947
Invented entities — nomi e luoghi inventati	Bias resiste con schema intatto	0.641
Pronoun variations — her / him / them	Bias resiste — il pattern non dipende dal pronome	0.557
Ablation tokens — rimuovi pezzi dello schema	Bias crolla sotto una soglia minima (nome + verbo + oggetto)	0.507
No proper nouns — solo "a guest", "an artist"	Bias parziale — necessario ma non sufficiente	0.306
Name substitution — Shaggy, Drake, Rihanna...	Bias scompare — il pattern è sensibile al nome-simbolo	0.012

L'ipotesi regge. Serve un *metodo* che la *localizzi*.

IG è correlazionale; Activation Patching si rompe sulle lunghezze diverse. Per provare che il circuito del pattern esiste — e dove — servono strumenti causali che tollerino P di lunghezza variabile, o esperimenti controllati a parità di token.

→ IDEE SUL PROSSIMO METODO?

Cosa c'è sotto il cofano.

MODELLO	**cross-encoder/nli-deberta-v3-large** · 24 layer · fine-tuned su SNLI + MultiNLI + FEVER-NLI + ANLI
ATTENTION	hyp_dominance = attention flow CLS → H / CLS → (P+H); soglia bias-sospetto 0.65
IG	Layer Integrated Gradients (Captum) · 50 steps · baseline = PAD con CLS/SEP preservati · target = logit entailment
PATCHING	Residual stream, per (layer, posizione) · patching clean←corrupt · metrica: (E_patched − E_clean) / (E_corrupt − E_clean)
PAPER · IG	Sundararajan, Taly & Yan, *Axiomatic Attribution for Deep Networks*, ICML 2017
PAPER · PATCHING	Meng, Bau, Andonian & Belinkov, *Locating and Editing Factual Associations in GPT* (ROME), NeurIPS 2022
PAPER · BIAS	McKenna et al., *Sources of Hallucination by LLMs on Inference Tasks*, Findings of EMNLP 2023 (attestation bias)